architecture 鐿鈦 AI 平台總體架構（HowardAGent／HowardRoute／HowardPro）

L5 使用者入口
Channels

- Teams Bot
- 員工入口網站
- LINE 推播
- 產線看板／儀表板
- 行動簽核

提問

L4 AI 產品
AI Products

- 品質 Copilot
- NCR／CAPA 初稿
- 報價助理
- 供應鏈預警
- AI 價值儀表板

L3 HowardAGent
AI Agent 應用中樞

- Orchestrator
  任務規劃
- Agentic RAG
  強制附版本與來源
- OCR Agent
  發票／檢驗報告
- MCP Hub
  SAP／MES／QMS 受控工具
- Text2SQL
  只讀

人員核可閘道：寫回 SAP／MES／QMS、放行批號、改單一律人工核可＋Part 11 電子簽章

LLM 呼叫一律經網關　　預測 API

L2 模型與預測
Model & Prediction

HowardRoute　OpenRouter 式多模型網關

- OpenAI 相容 API
- 身分與遮罩
- Smart Routing
  省 20–40% Token
- 毫秒級備援
  429／斷線切換
- 計量與部門分攤
- 稽核日誌
- 快取
- **地端 LLM**（南屯 GPU）
  機密／客戶機密
- **雲端 LLM**（零資料保留）
  僅限非機密

HowardPro　AI 製造預測核心

- AutoML
  CNC 參數建議
- 刀具壽命預測
- 虛擬量測
- SPC 異常預警
- Domain Twin
  數位技師
- AILM
  版本／漂移／根因

特徵／訓練資料

L1 資料產品
Lakehouse & Data Products

- Bronze
- Silver
- Gold 資料產品
- Feature Store
- 向量庫 Qdrant
- Catalog（DataHub）
- MDM 主資料

Iceberg + Trino；資料契約、血緣與品質規則（DQ）隨資料產品發布

串流／CDC

L0 雙環匯流排
IT 環 ＋ OT 環

- Kafka
  IT 事件環
- EMQX MQTT
  OT 遙測環
- Debezium CDC
- Edge Gateway
  工業 DMZ
- Schema Registry

OT 區經工業 DMZ 單向上送（IEC 62443 分區）；AI 不直接控制機台

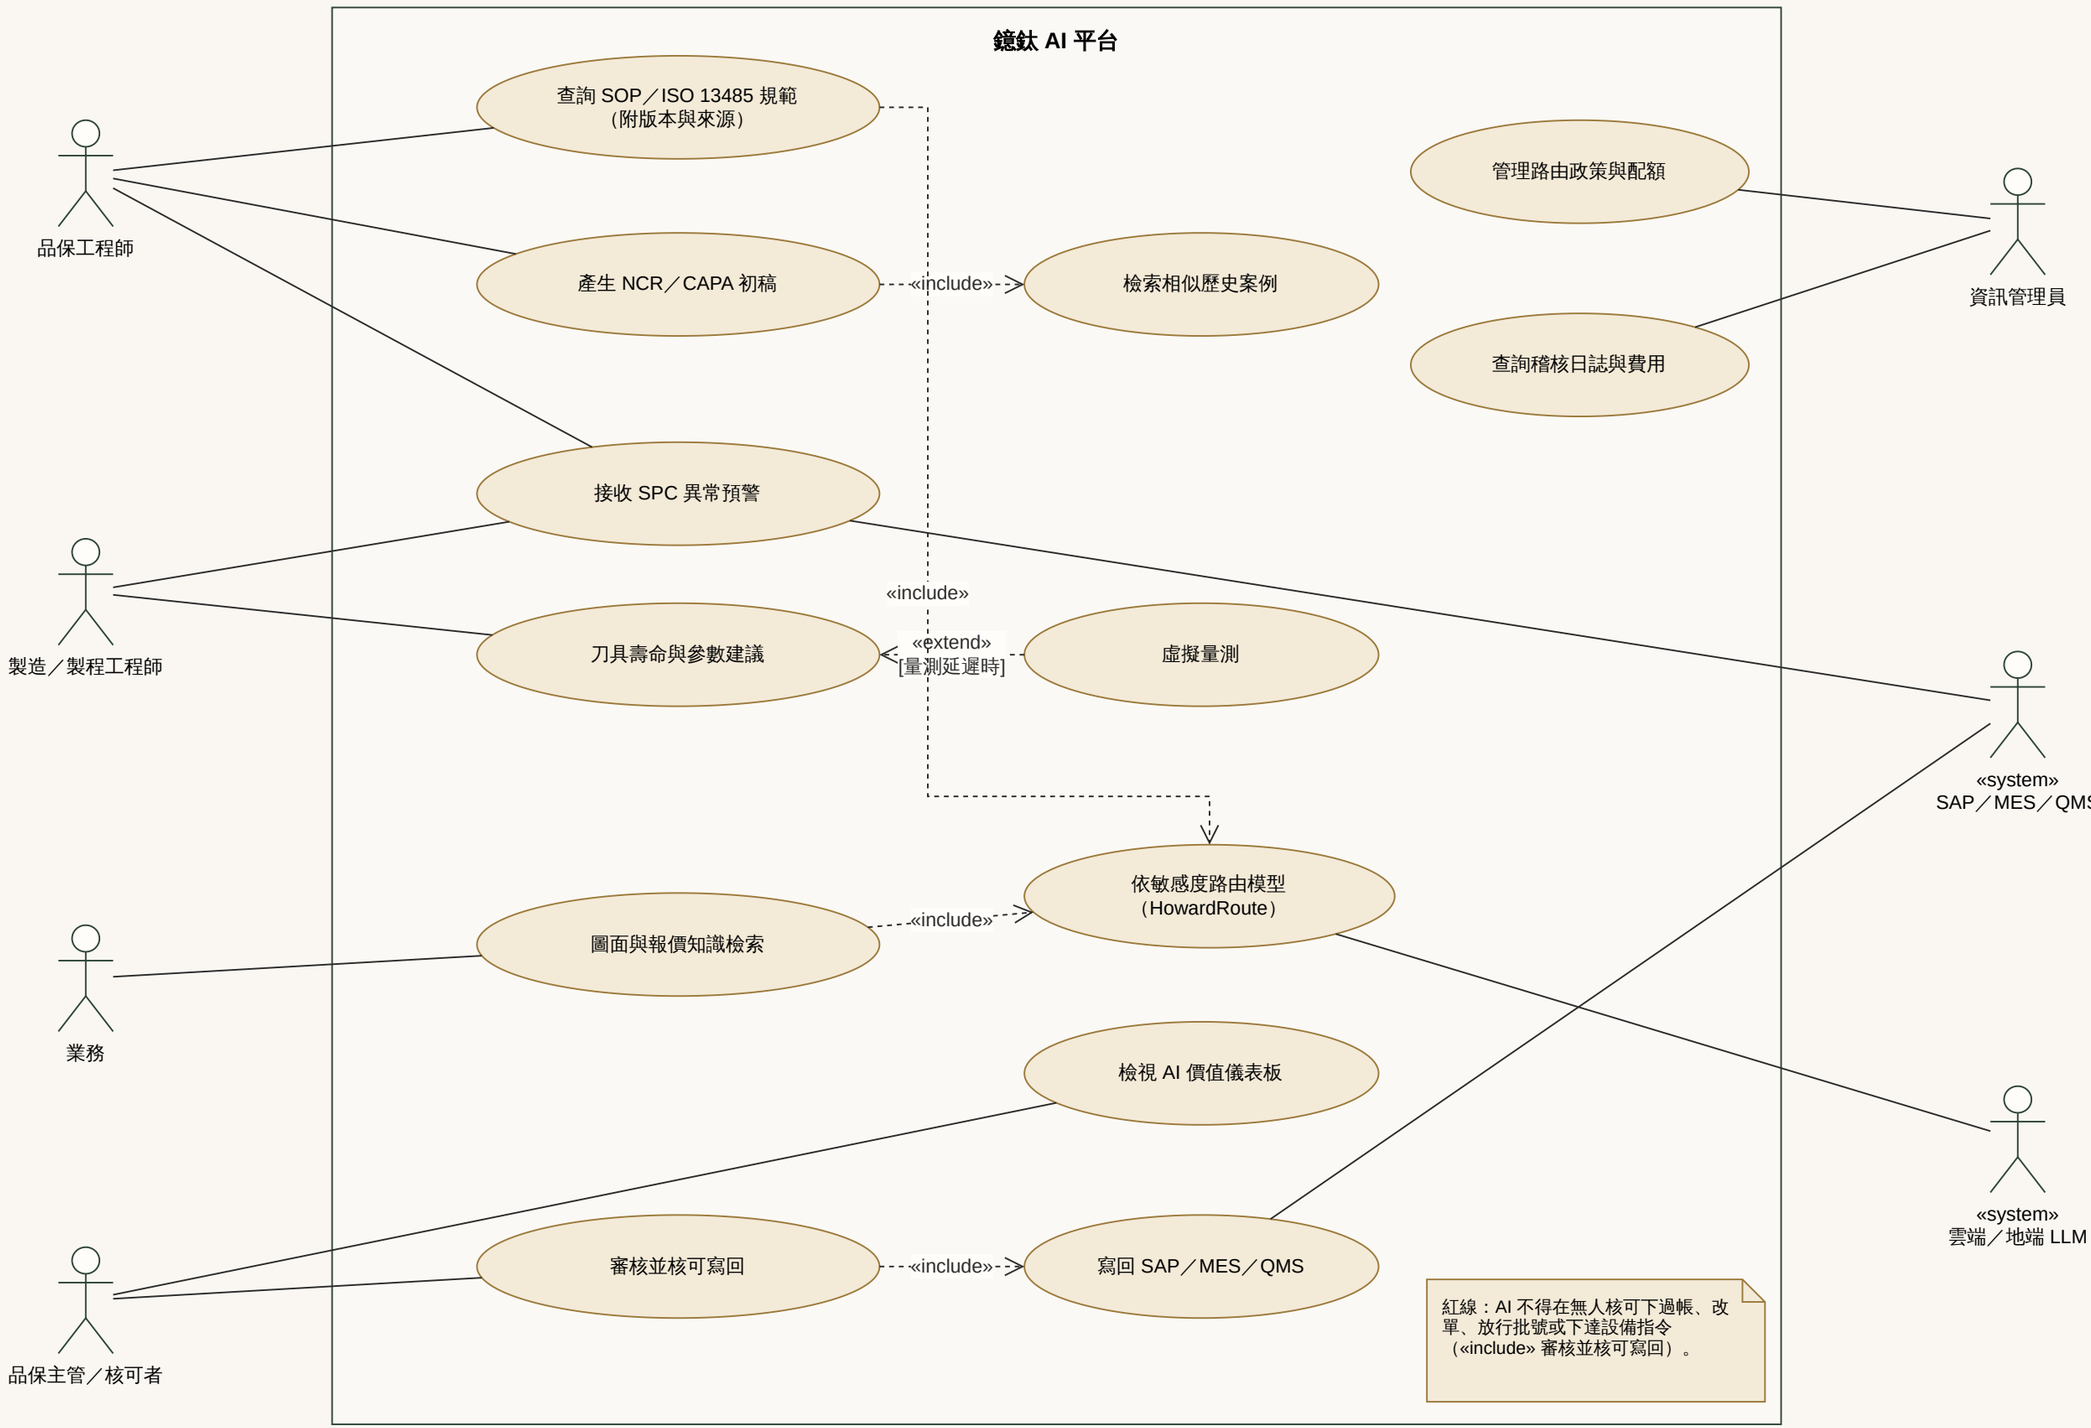
來源系統

- SAP S/4HANA
- MES
- PLM
- QMS
- Notes 遺留系統
- 后里 OT 區
  CNC／CMM

治理與安全主軸
Governance（貫穿各層）

- ISO 42001 AI 管理系統
- ISO 27001 資訊安全
- ISO 13485／21 CFR Part 11
  ALCOA+ 稽核軌跡
- IEC 62443 OT 分區
- 資料分級
  公開／內部／機密／客戶機密
- Keycloak SSO ＋ RBAC
- APISIX API 閘道
- 模型風險與漂移審查
- 供應商合約：零資料保留
- FinOps：Token 成本分攤

uc 鐿鈦 AI 平台（HowardAGent／HowardRoute／HowardPro）



class 核心領域模型

User
- id: UUID
- name: String
- dept: Department

+ hasRole(r: Role): Boolean

AgentSession
- id: UUID
- channel: Channel
- startedAt: DateTime

+ ask(q: String): AgentTask

AgentTask
- id: UUID
- type: TaskType
- state: TaskState
- sensitivity: Sensitivity

+ plan(): Step[*]
+ run(): Result
+ requestApproval(): Approval

«interface»
Tool
- name: String
- readOnly: Boolean

+ invoke(args): ToolResult

HowardAGent：AgentSession、AgentTask、Tool、Retriever
HowardRoute：ModelGateway、RoutingPolicy、ModelRoute、ModelProvider
HowardPro：PredictionModel、Prediction

Role
- code: String
- dataLevel: Sensitivity

SapQueryTool
+ invoke(args): ToolResult

QmsTool
+ invoke(args): ToolResult

Citation
- docNo: String
- version: String
- span: TextRange

Retriever
- index: VectorIndex

+ search(q, k): Citation[*]

«enumeration»
Sensitivity
公開
內部
機密
客戶機密

«interface»
ModelGateway
- endpoint: URL

+ complete(req: LlmRequest): LlmResponse
+ select(req): ModelRoute

Approval
- approver: User
- decision: Decision
- signedAt: DateTime
- reason: String

+ sign(u: User, d: Decision)

KnowledgeDoc
- docNo: String
- version: String
- effective: Date

RoutingPolicy
- sensitivity: Sensitivity
- taskType: TaskType
- maxCost: Money

+ matches(req): Boolean

HowardRoute
- policies: RoutingPolicy[*]
- cache: ResponseCache

+ complete(req): LlmResponse
+ select(req): ModelRoute
- failover(r: ModelRoute)

«HowardPro»
PredictionModel
- version: String
- target: Metric

+ predict(f: FeatureVector): Prediction

Prediction
- value: Float
- confidence: Float
- at: DateTime

UsageRecord
- tokens: Integer
- cost: Money
- dept: Department

ModelRoute
- priority: Integer
- timeoutMs: Integer

ModelProvider
- name: String
- onPrem: Boolean
- zeroRetention: Boolean

Machine
- assetNo: String
- plant: Plant

Lot
- lotNo: String
- udi: String

uses
calls
indexes
records
trainedOn

object NCR 初稿請求的執行快照（2026-11-06 09:42）

chen : User
name = "陳工程師"
dept = 品保部

s-0915 : AgentSession
channel = Teams
startedAt = 09:41:58

t-2261 : AgentTask
type = NCR_DRAFT
state = PendingApproval
sensitivity = 機密

p-conf : RoutingPolicy
sensitivity = 機密
taskType = NCR_DRAFT
maxCost = NT$ 3

about

L2611-0042 : Lot
lotNo = "L2611-0042"
udi = "(01)0471…(10)L2611-0042"

c1 : Citation
docNo = "QP-8.3-01"
version = "C"

r1 : ModelRoute
priority = 1
timeoutMs = 8000

c2 : Citation
docNo = "NCR-2025-0412"
version = "final"

u-77310 : UsageRecord
tokens = 3,412
cost = NT$ 0.9
dept = 品保部

onprem-llm : ModelProvider
name = "地端 LLM（南屯 GPU）"
onPrem = true
zeroRetention = true

a-2261 : Approval
approver = 林主管
decision = (pending)

機密等級 → RoutingPolicy 只允許地端模型；客戶圖面與報價不會送往雲端模型。

cmp 鏡鈦 AI 平台元件與介面

«component»
Teams Bot／入口網站／產線看板

«use»

IAgent

«component»
HowardAGent
Agentic RAG · OCR Agent · MCP Hub

ILlmGateway（OpenAI 相容）

«use»

«component»
HowardRoute
Smart Routing · Failover · 遮罩 · 計費

HTTPS

«external»
雲端 LLM 供應商

«use»

«component»
Vector DB（Qdrant）

«use»

IPredict

«use»

HTTPS（內網）

«component»
地端 LLM（GPU）

«component»
API Gateway（APISIX）

«component»
HowardPro
AutoML · 虛擬量測 · Domain Twin · AILM

ITool（MCP）

«system»
SAP／MES／PLM／QMS／Notes

«use»

IAuth

REST／IDoc

«use»

CDC（Debezium）

«component»
Keycloak（SSO／OIDC）

IDataProduct

«component»
Lakehouse（Bronze／Silver／Gold）

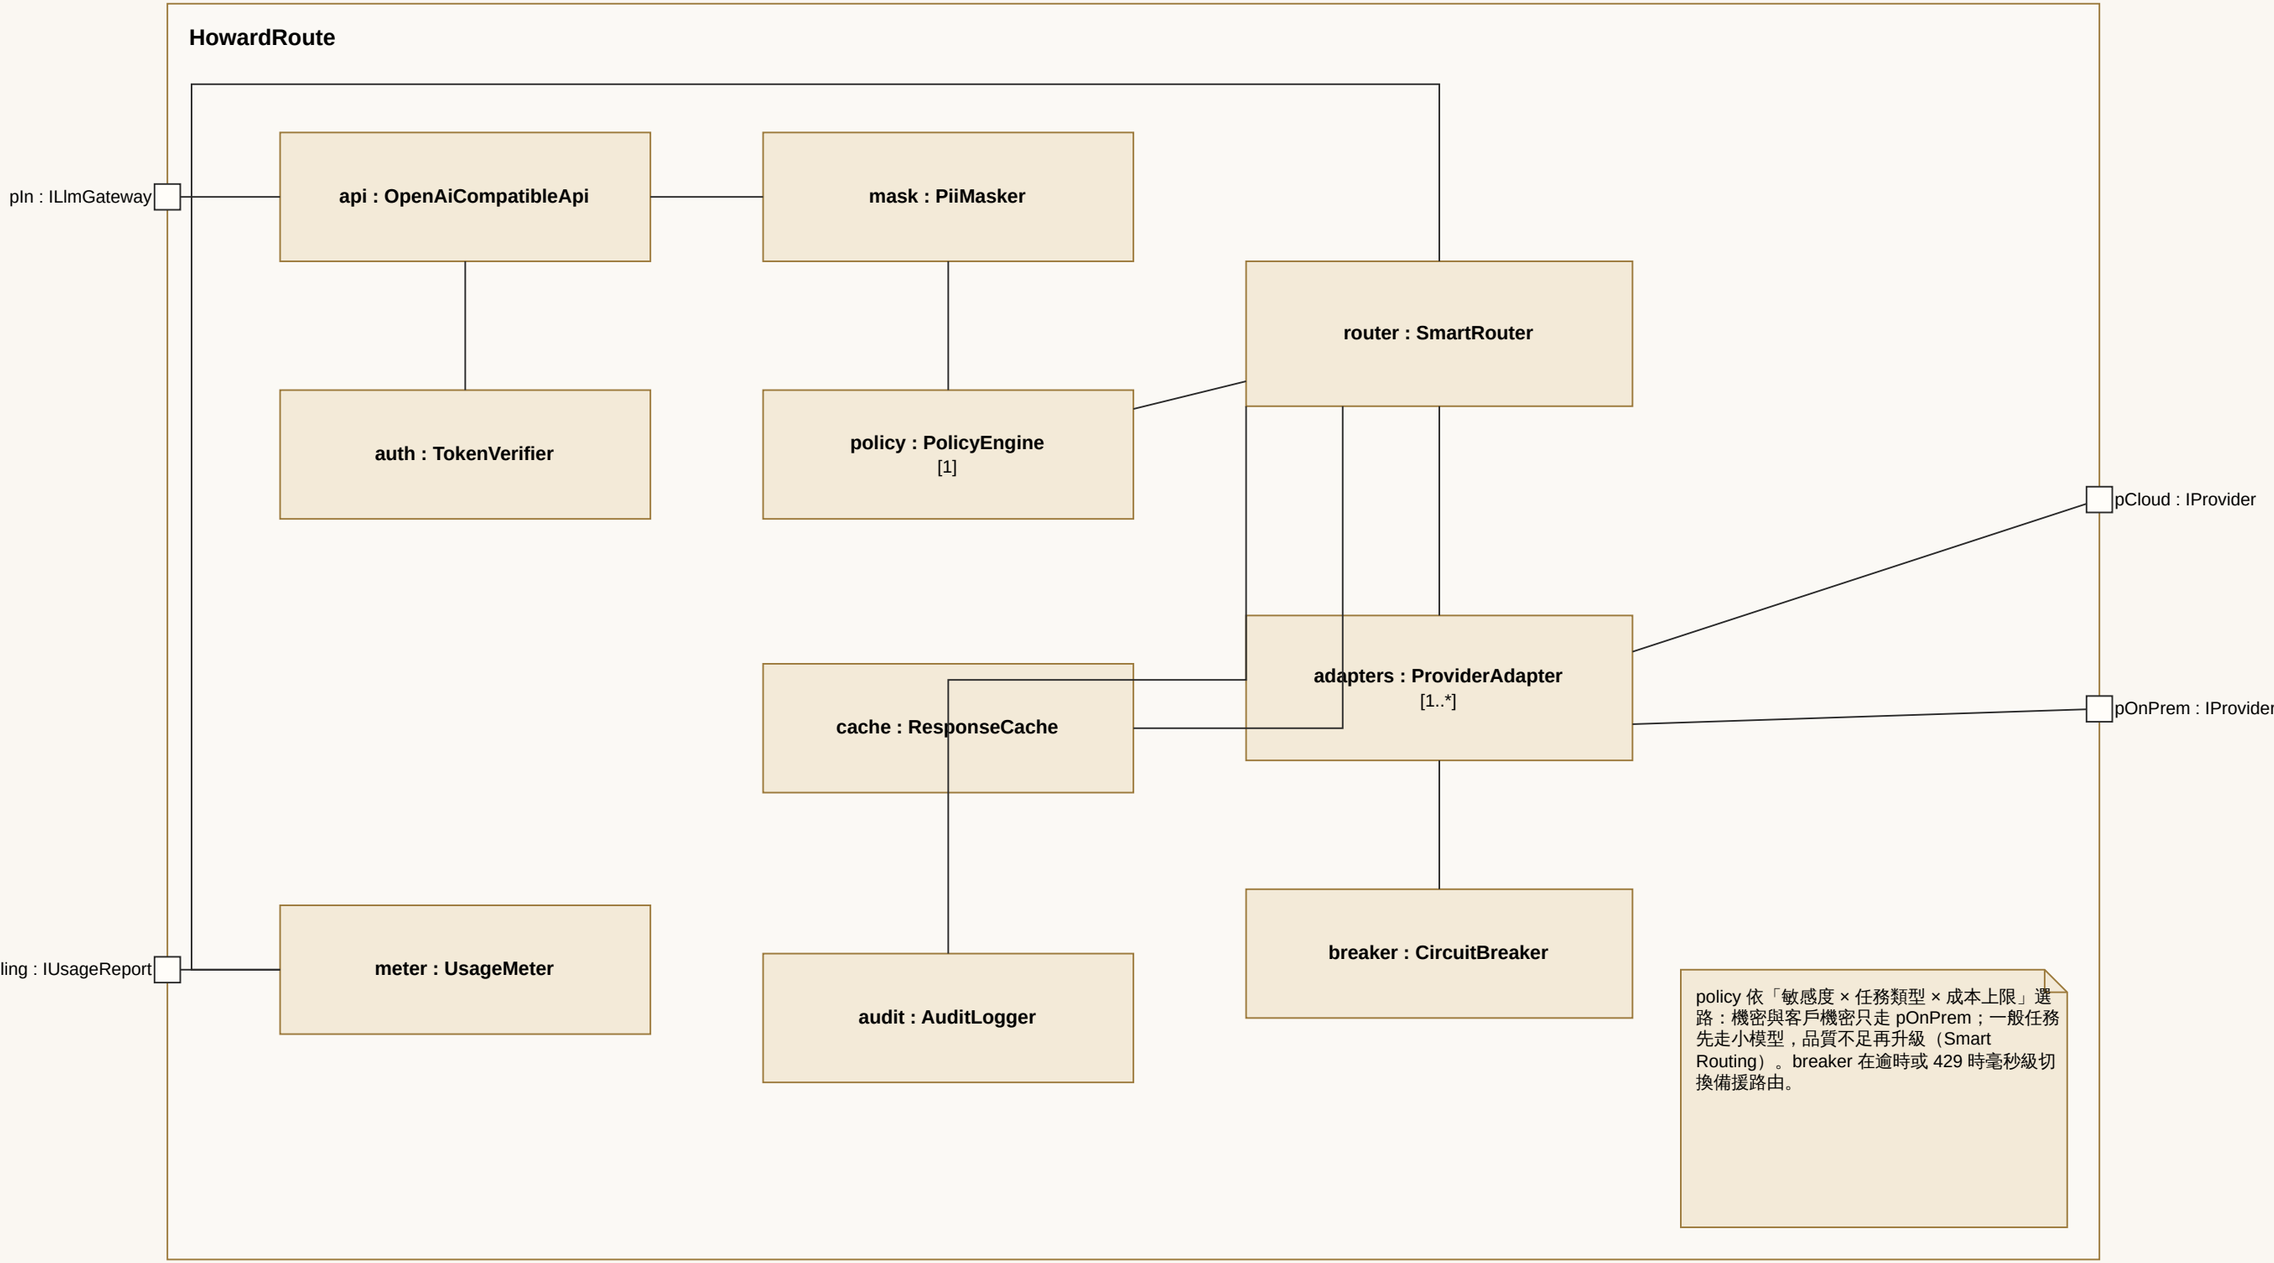
IEventStream

«use»

«component»
Data Bus（Kafka＋EMQX）

三個核心元件：**HowardAGent**（AI Agent 應用中樞）、**HowardRoute**（OpenRouter 式多模型網關）、**HowardPro**（AI 製造預測）。外部系統只經 API Gateway 與 Data Bus 進出。

composite HowardRoute 內部結構



pkg 平台分層套件

L5 使用者入口

teams-bot

portal

line-dashboard

«import»

L4 AI 產品

quality-copilot

quote-assistant

supply-alert

«import»

«apply»

«access»

L3 HowardAGent

orchestrator

rag

ocr-agent

mcp-hub

«access»

L2 HowardRoute

router

policy

L2 HowardPro

automl

vm

ailm

«import»

«import»

«import»

L1 資料產品與湖倉

bronze

silver

gold

feature-store

catalog（DataHub）

mdm

«import»

L0 雙環資料匯流排與系統來源

kafka

emqx

debezium-cdc

edge-gateway

sap／mes／plm／qms

notes

«governance» 治理與安全

iso42001-policy

data-classification

iec62443-zones

part11-audit-trail

model-risk

vendor-contracts

deployment 南屯總部・后里廠・雲端

«HTTPS» 僅非機密資料

«device»
南屯總部資料中心

«executionEnvironment»
Kubernetes 叢集（3 nodes）

«artifact»
howard-agent.jar

«artifact»
howard-route.jar

«artifact»
howard-pro.whl

«artifact»
apisix

«artifact»
keycloak

«artifact»
kafka

«HTTPS» 內網

«device»
地端 GPU 伺服器

«MQTT／TLS»

«artifact»
llm-onprem.gguf

«artifact»
vllm-server

«JDBC／gRPC»

«device»
資料湖倉／向量庫

«artifact»
iceberg／trino

«artifact»
qdrant

«device»
工業 DMZ

«artifact»
edge-gateway

«artifact»
emqx-broker

«OPC UA» 單向上送

«device»
后里廠 OT 區

«artifact»
opc-ua-adapter

«artifact»
cnc／cmm 機台

«executionEnvironment»
雲端 LLM 供應商

IEC 62443 分區：OT 區不直接連網，只經工業 DMZ 單向上送；AI 不直接控制機台。

«RFC／IDoc／CDC»

«device»
SAP／MES／PLM／QMS

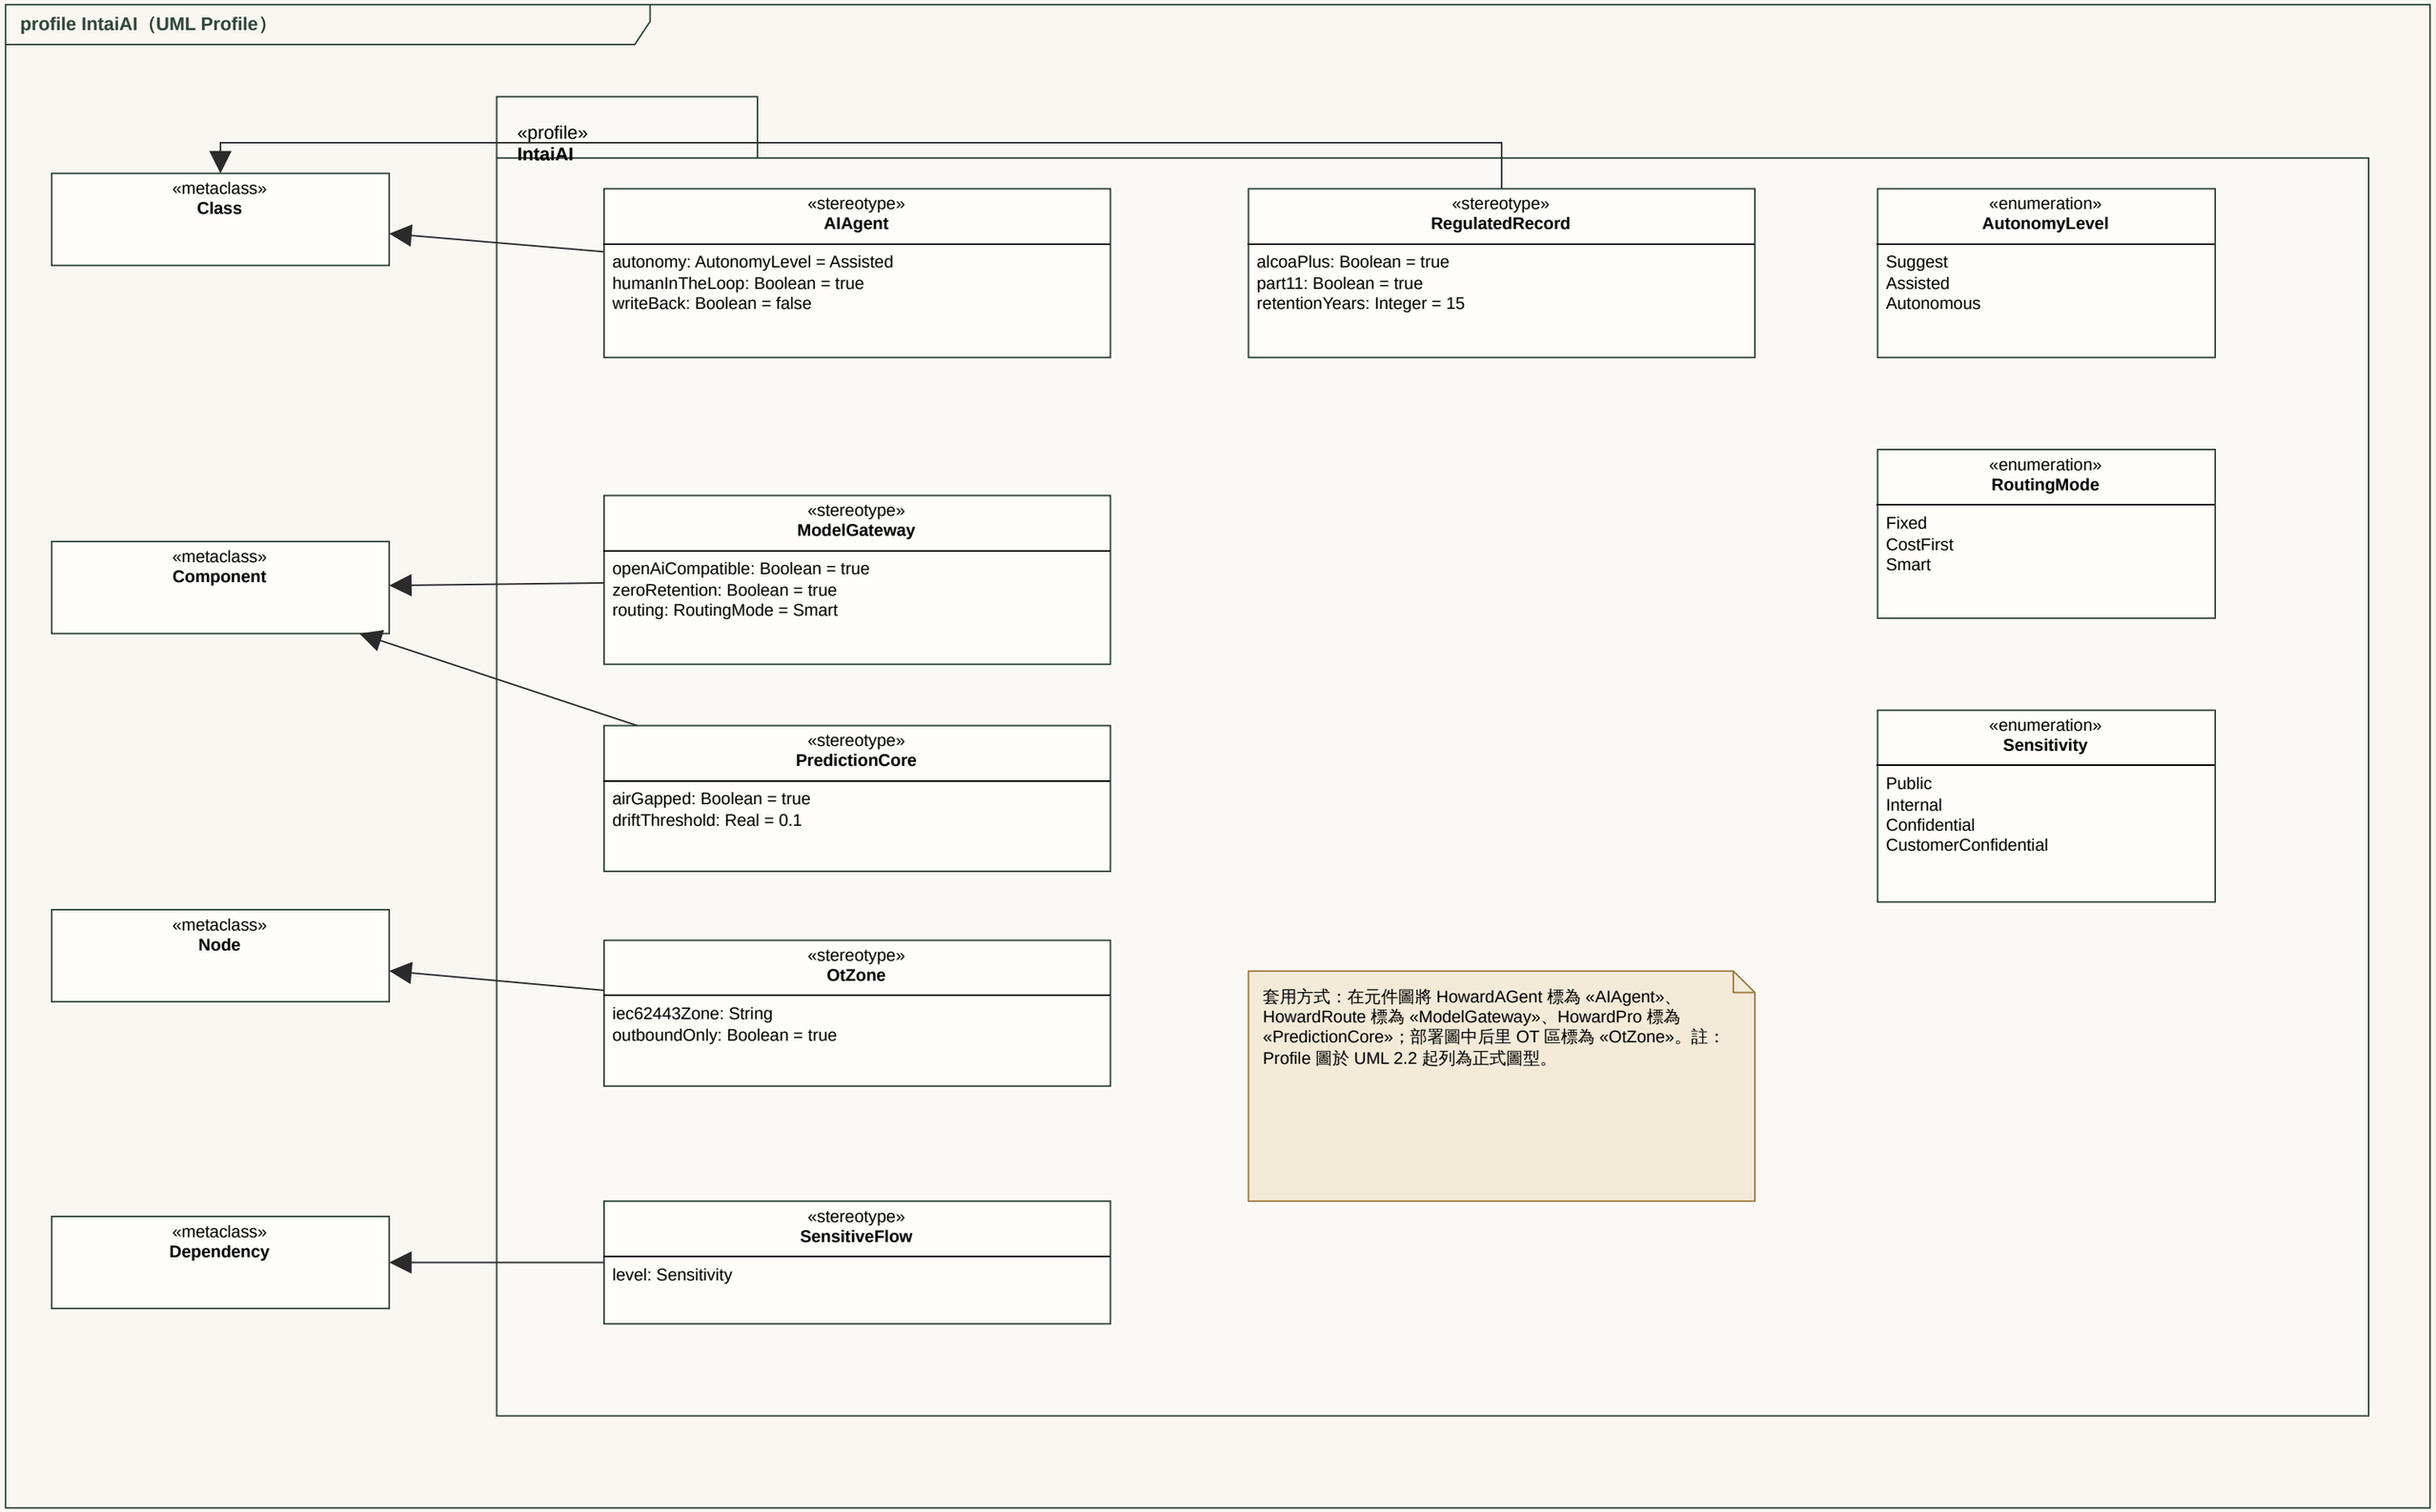
«artifact»
sap-s4

«artifact»
mes

«HTTPS／SSO»

«device»
員工裝置

«artifact»
teams client

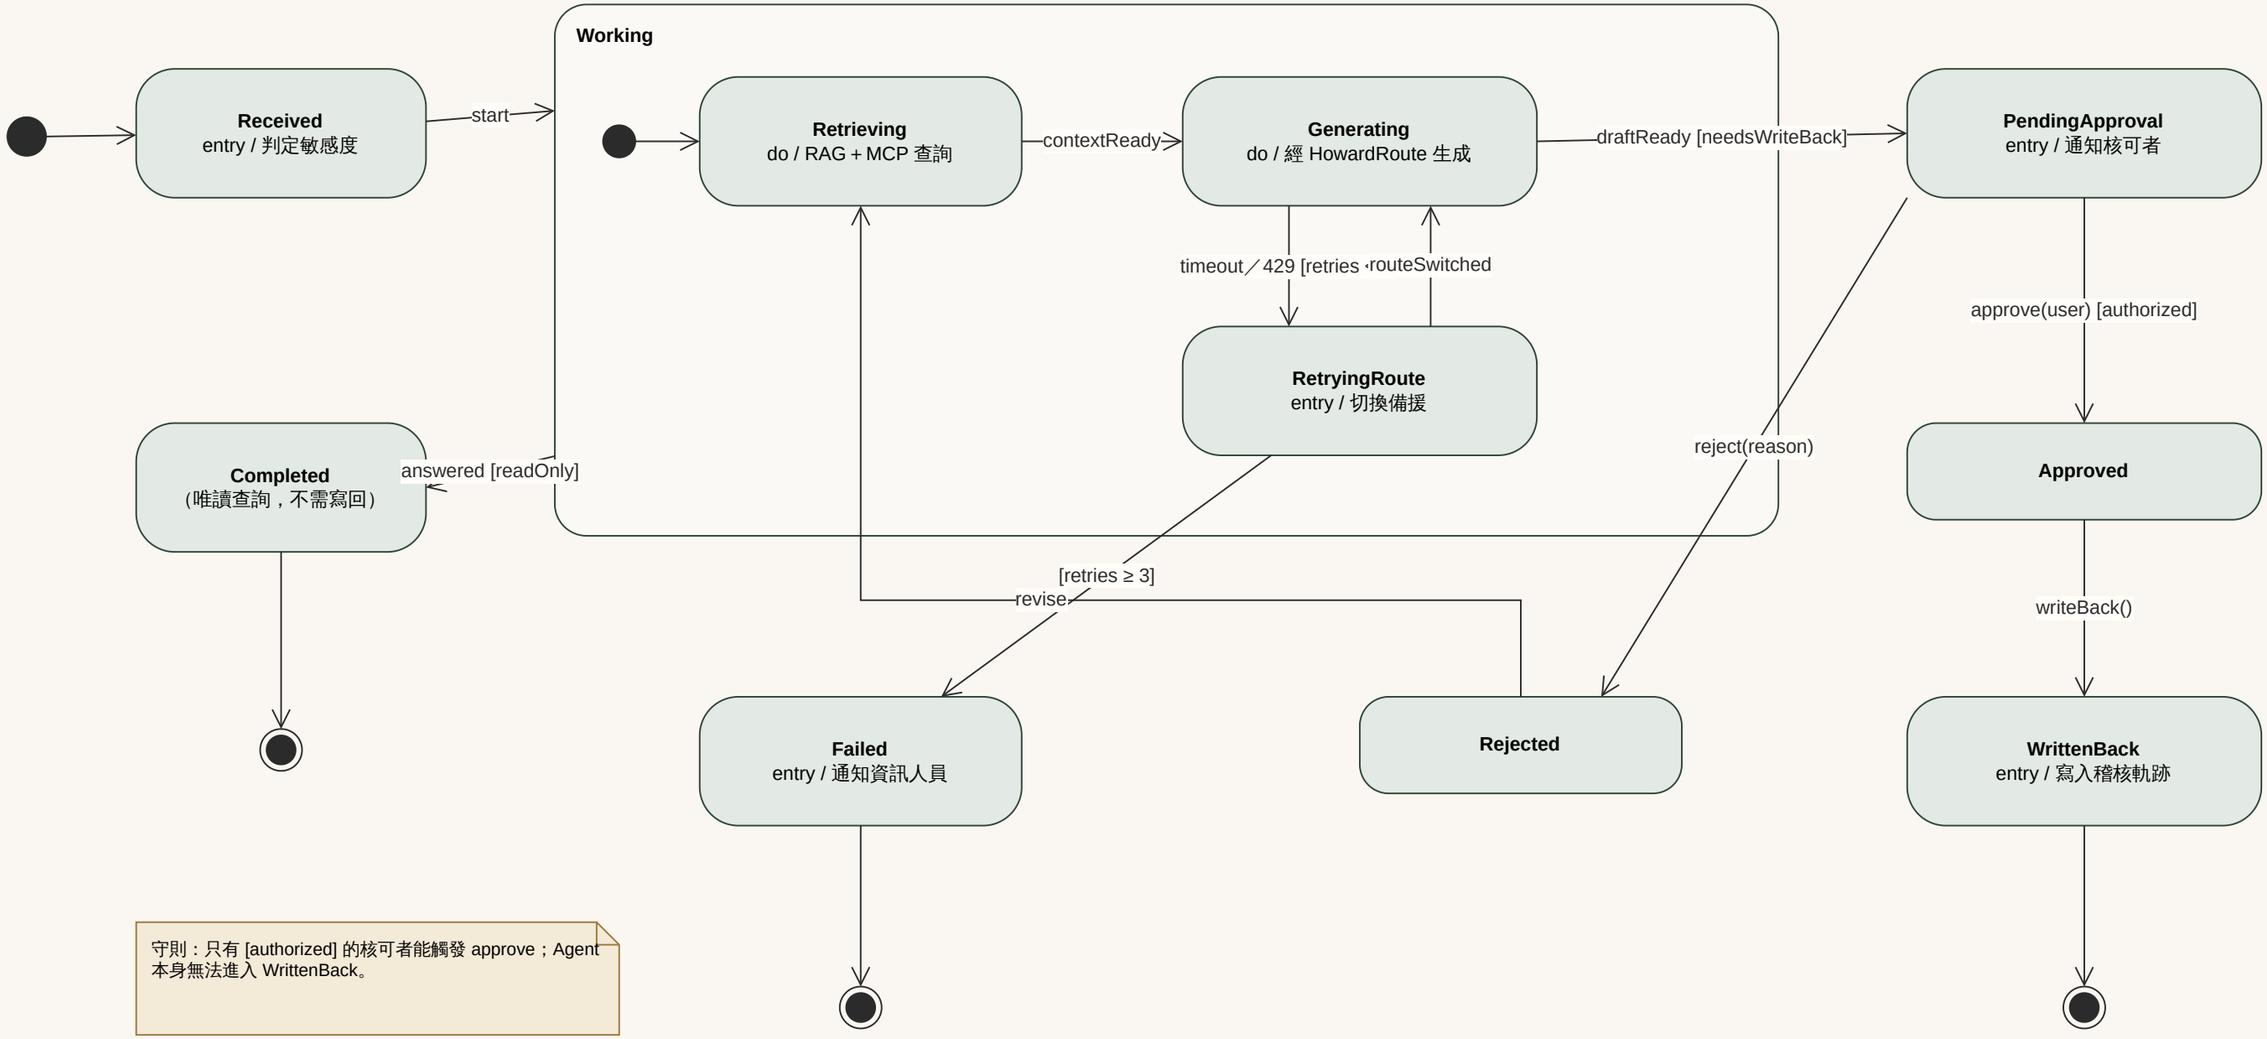

profile IntaiAI（UML Profile）
«profile»
IntaiAI
«metaclass»
Class
«metaclass»
Component
«metaclass»
Node
«metaclass»
Dependency
«stereotype»
AIAgent
autonomy: AutonomyLevel = Assisted
humanInTheLoop: Boolean = true
writeBack: Boolean = false
«stereotype»
ModelGateway
openAiCompatible: Boolean = true
zeroRetention: Boolean = true
routing: RoutingMode = Smart
«stereotype»
PredictionCore
airGapped: Boolean = true
driftThreshold: Real = 0.1
«stereotype»
OtZone
iec62443Zone: String
outboundOnly: Boolean = true
«stereotype»
SensitiveFlow
level: Sensitivity
«stereotype»
RegulatedRecord
alcoaPlus: Boolean = true
part11: Boolean = true
retentionYears: Integer = 15
套用方式：在元件圖將 HowardAGent 標為 «AIAgent»、HowardRoute 標為 «ModelGateway»、HowardPro 標為 «PredictionCore»；部署圖中后里 OT 區標為 «OtZone»。註：Profile 圖於 UML 2.2 起列為正式圖型。
«enumeration»
AutonomyLevel
Suggest
Assisted
Autonomous
«enumeration»
RoutingMode
Fixed
CostFirst
Smart
«enumeration»
Sensitivity
Public
Internal
Confidential
CustomerConfidential

act NCR／CAPA 初稿產生與核可寫回

品保工程師
HowardAGent
HowardRoute
品保主管

在 Teams 描述不良現象
（附批號、照片）
判定敏感度與任務類型
MCP：查 QMS 檢驗紀錄
RAG：找 SOP 與相似 NCR
組裝提示與引用
依政策選模型
（機密 → 地端）
產生 NCR／CAPA 初稿
[逾時／429]
毫秒級切換備援路由
[成功]
初稿＋引用來源
檢視初稿
送審
退回修改
[退回]
[核可]
電子簽核（Part 11）
寫回 QMS／SAP
並留稽核軌跡

stm AgentTask 生命週期



sd NCR 初稿：提問、選路、生成、核可寫回

:品保工程師
:Teams Bot
:HowardAGent
:MCP Hub
:Retriever
:HowardRoute
:地端 LLM
:品保主管
:QMS

1: 描述不良（批號 L2611-0042）
2: ask(q, user)

loop [每個資料來源]
3: invoke(qms.inspection, lot)
4: 檢驗紀錄
5: search(q, k=5)
6: citations[5]

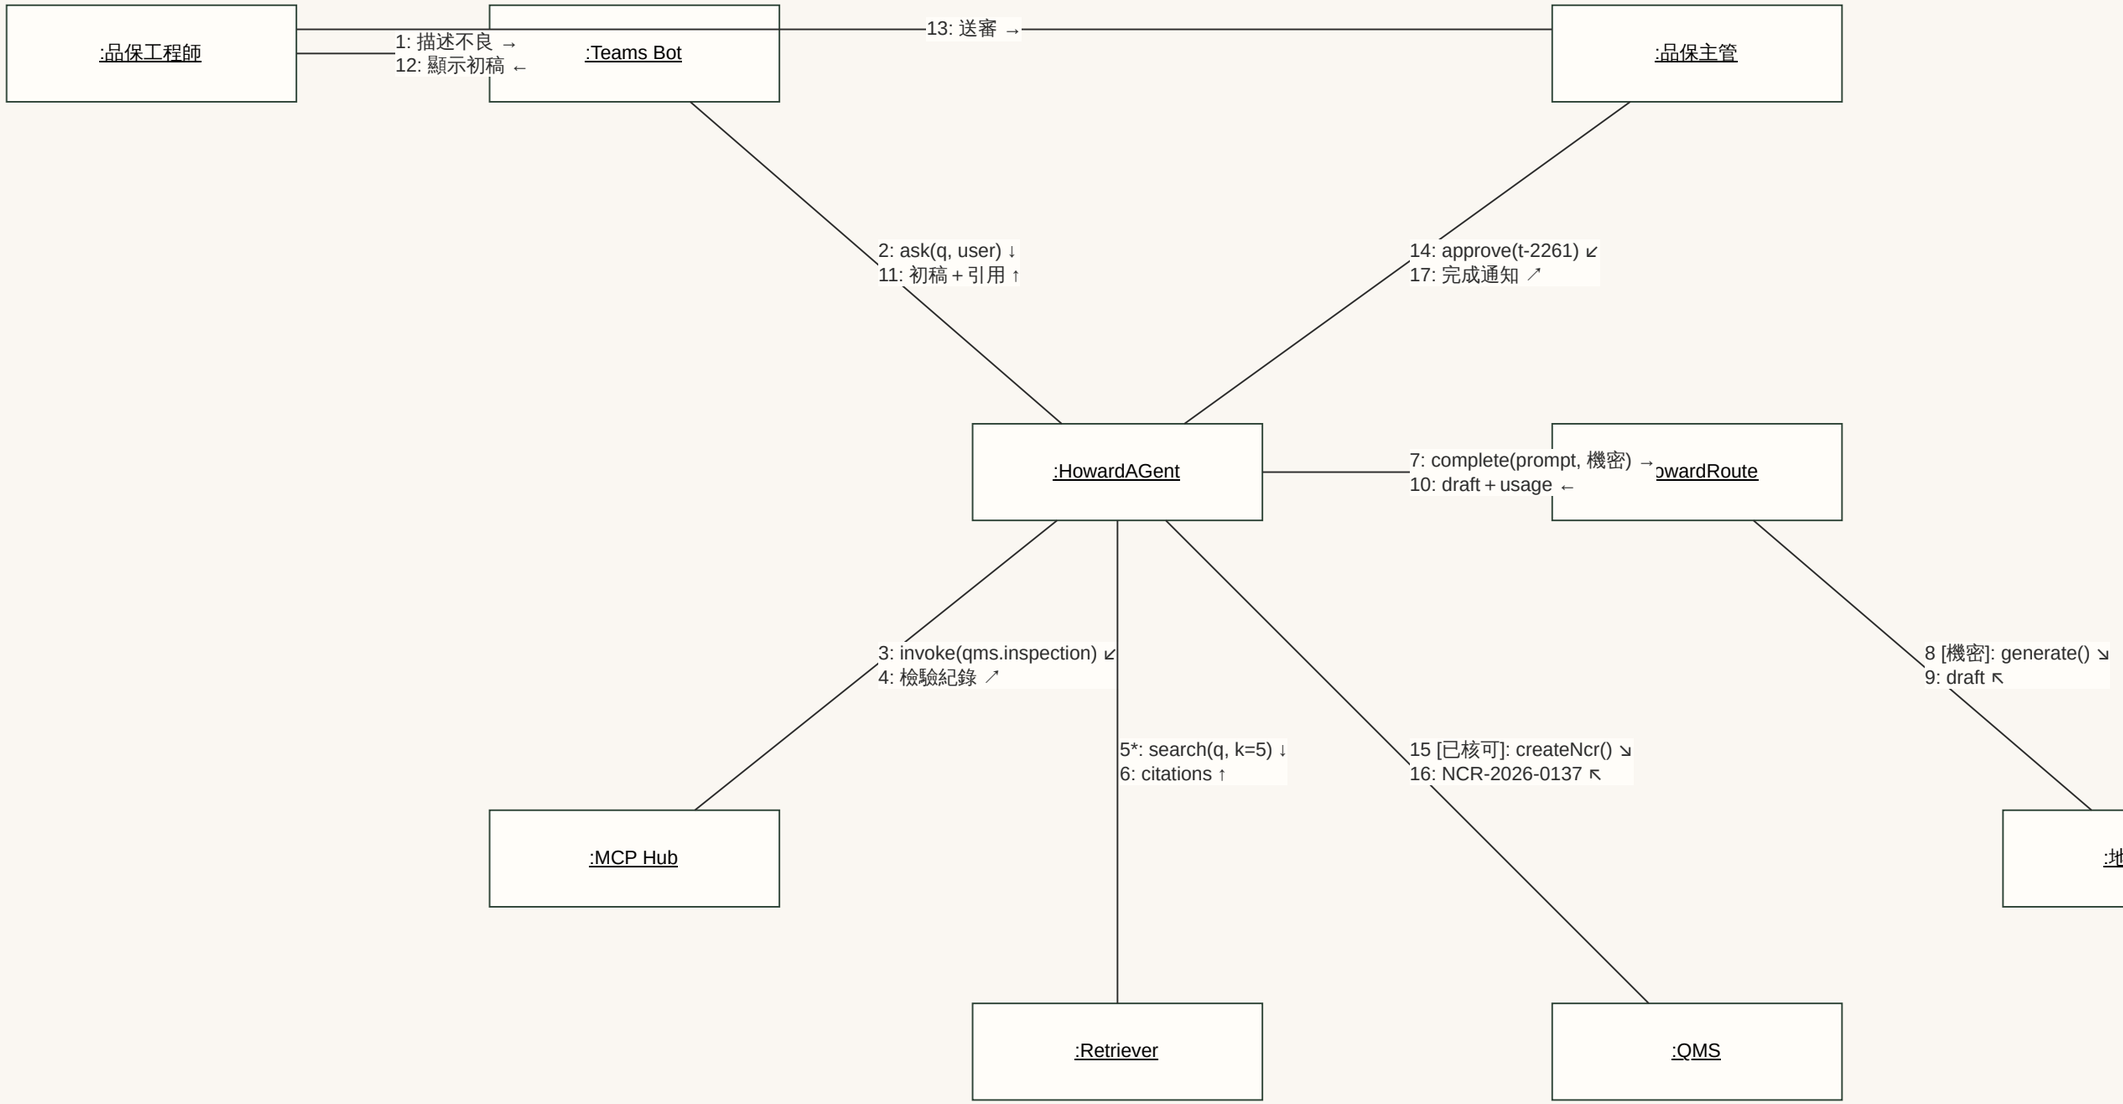
7: complete(prompt, sensitivity=機密)

alt [sensitivity ≥ 機密]
8: generate()
9: draft
[else] 可走雲端模型（Smart Routing）
10: draft + usage

11: 初稿 + 引用來源
12: 顯示初稿
13: 送審
14: approve(t-2261, 電子簽章)

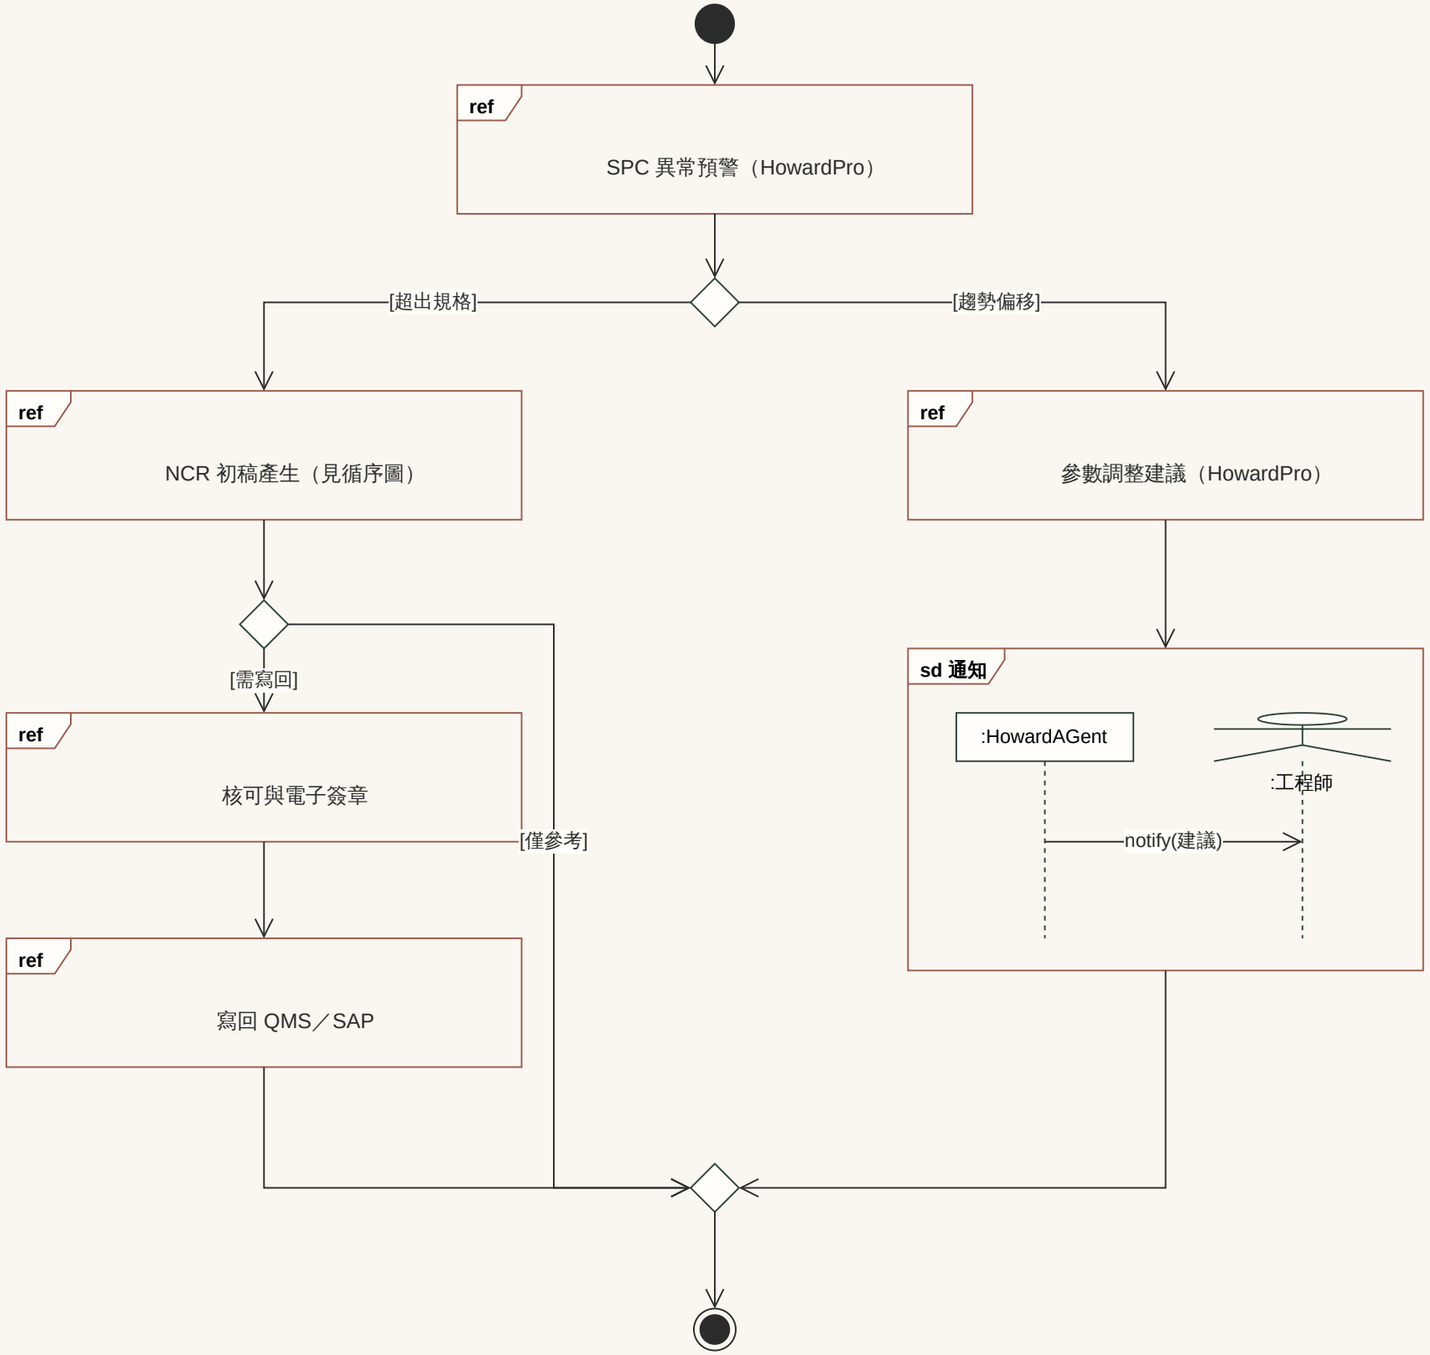
opt [已核可]
15: createNcr(draft, citations)
16: NCR-2026-0137
17: 完成通知

comm NCR 初稿（與循序圖相同情境）



訊息編號與循序圖一致；* 表示重複（每個資料來源），[ ] 為守衛條件。

interaction 品質事件處理總覽



timing SPC 異常 → 預警 → 處置（單一量測站）

數值為設計目標（SLO），到任後以實測校正。

:MES 量測流

超規

趨勢偏移

正常

{ 推論 ≤ 5 s }

:HowardPro

告警中

推論

監看

{ 告警到確認 ≤ 3 min }

alert(lot, 趨勢)

:工程師

處置

確認

閒置

{ 處置完成 ≤ 15 min }

t0

t0+2s

t0+5s

t0+30s

t0+3min

t0+12min

t0+15min

時間 →